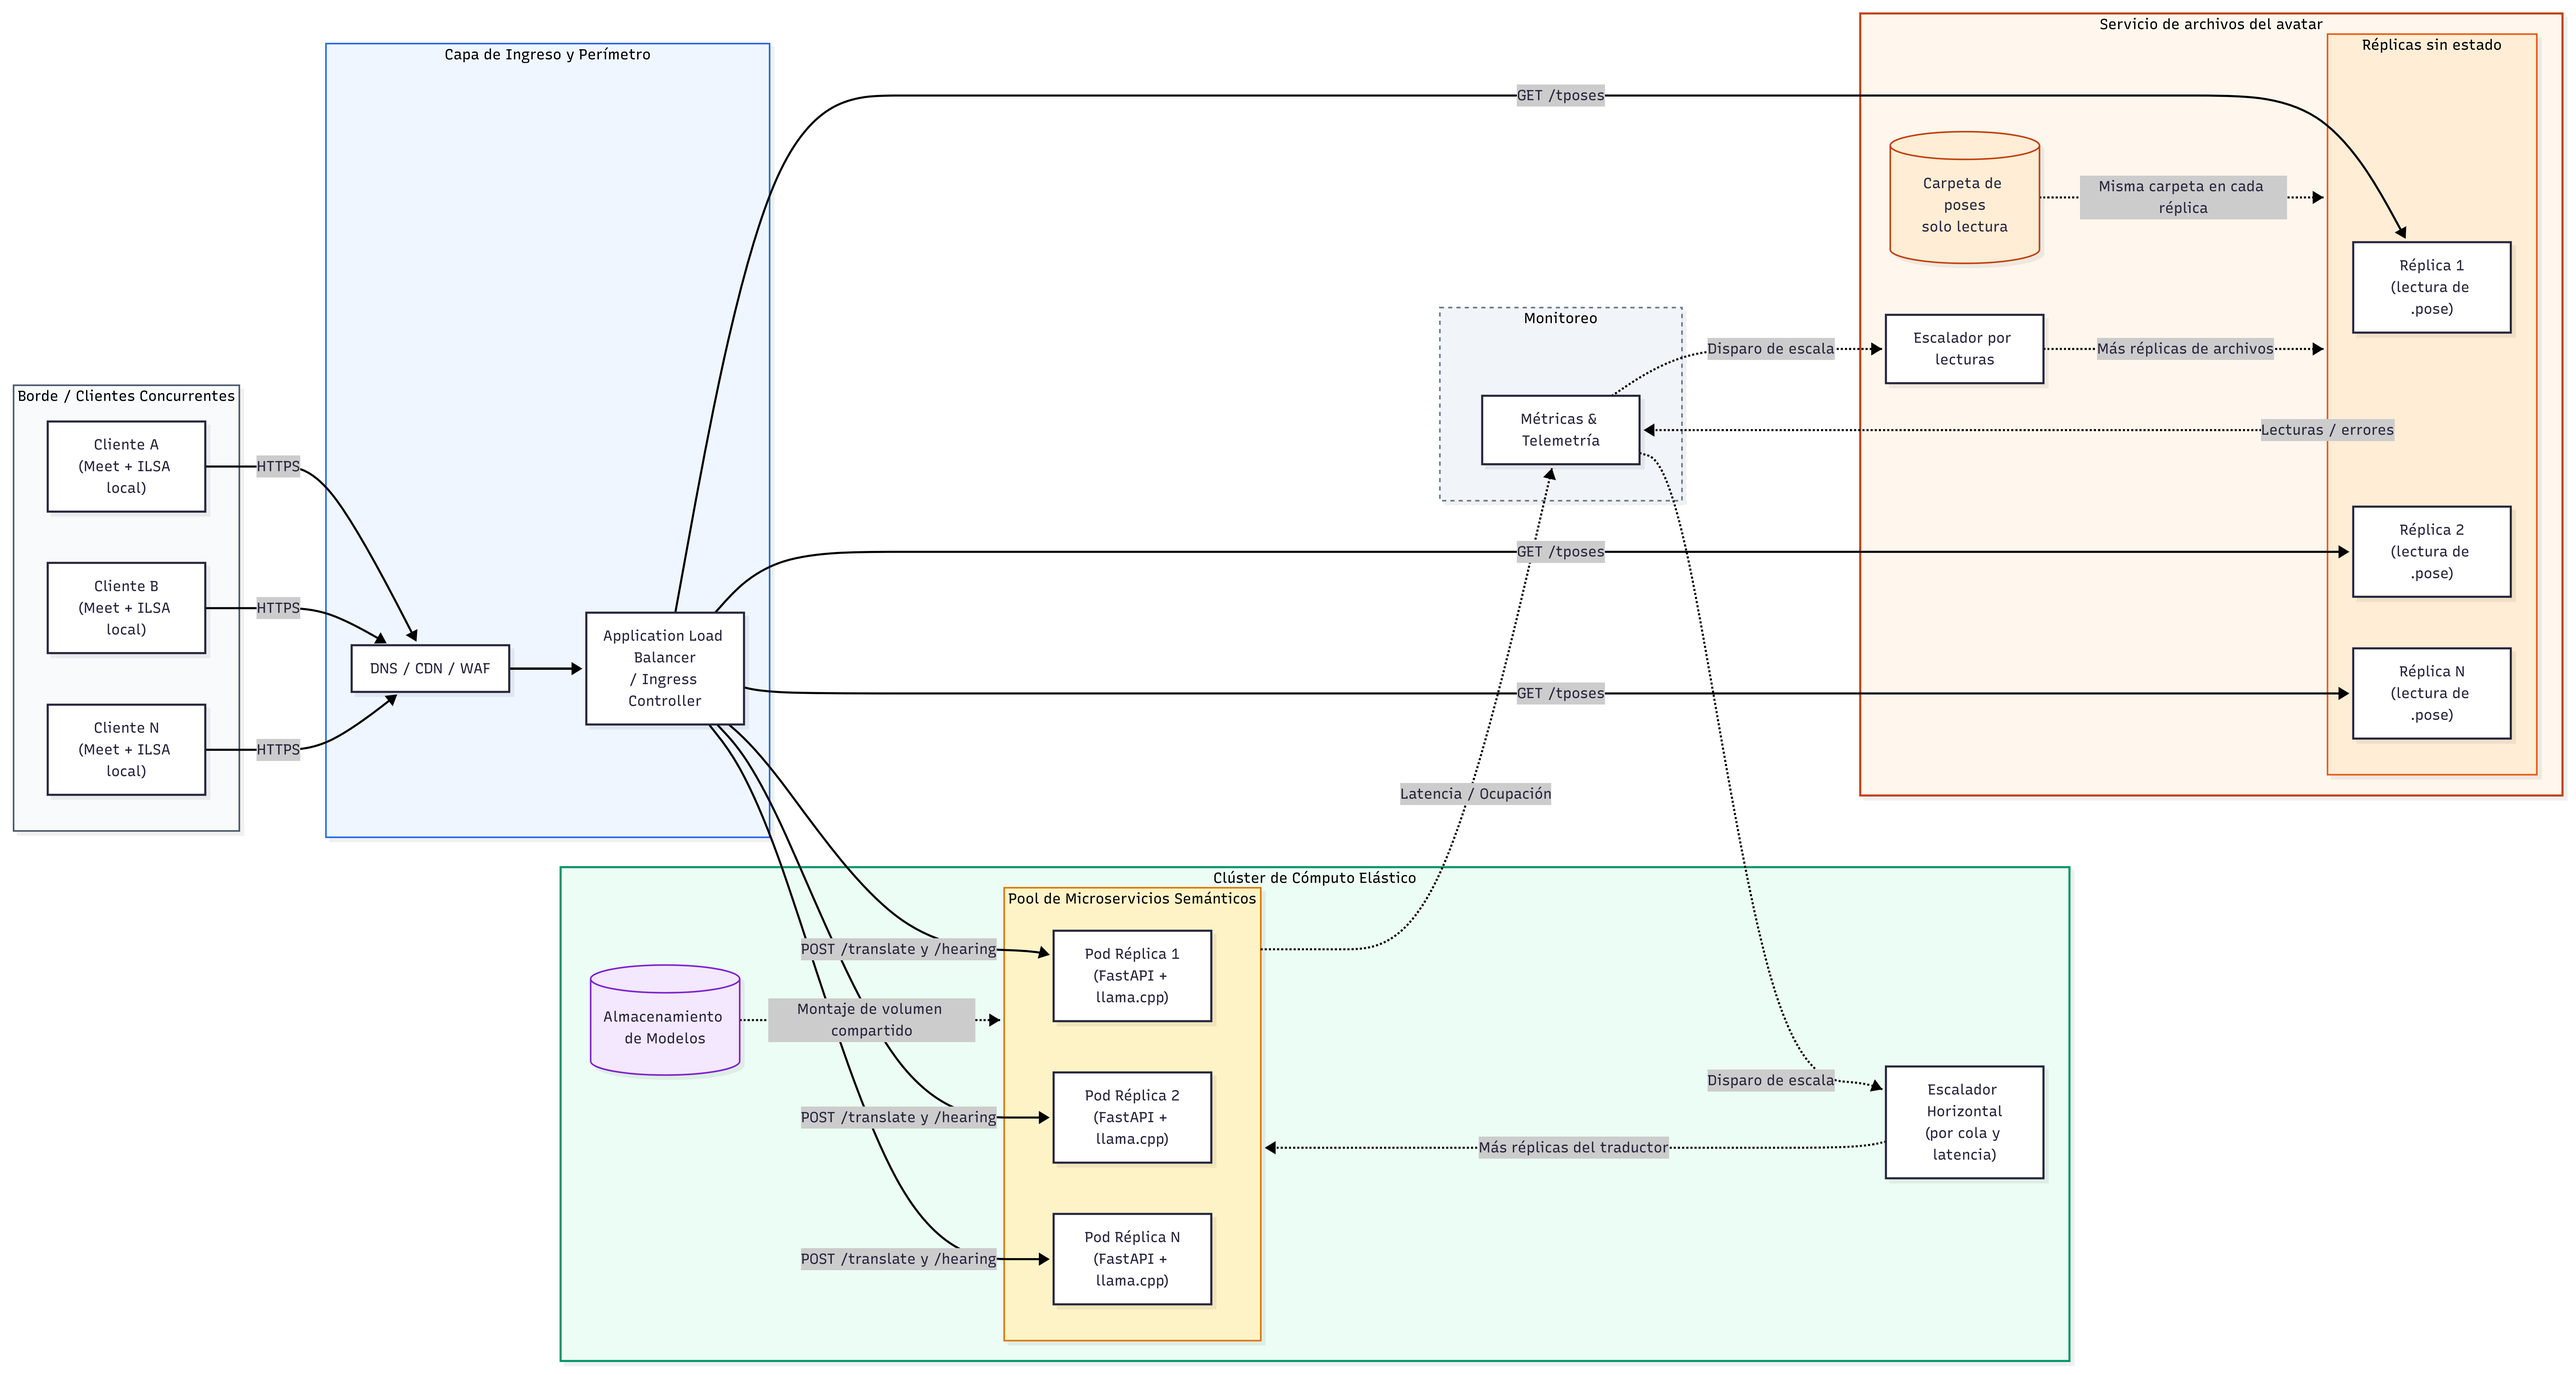

Capa de Ingreso y Perímetro
Servicio de archivos del avatar
Réplicas sin estado
Borde / Clientes Concurrentes
Cliente A (Meet + ILSA local)
Cliente B (Meet + ILSA local)
Cliente N (Meet + ILSA local)
HTTPS
HTTPS
HTTPS
DNS / CDN / WAF
Application Load Balancer / Ingress Controller
GET /tposes
GET /tposes
GET /tposes
Carpeta de poses solo lectura
Misma carpeta en cada réplica
Réplica 1 (lectura de .pose)
Réplica 2 (lectura de .pose)
Réplica N (lectura de .pose)
Monitoreo
Métricas & Telemetría
Disparo de escala
Escalador por lecturas
Más réplicas de archivos
Lecturas / errores
Latencia / Ocupación
Clúster de Cómputo Elástico
Pool de Microservicios Semánticos
POST /translate y /hearing
POST /translate y /hearing
POST /translate y /hearing
Pod Réplica 1 (FastAPI + llama.cpp)
Pod Réplica 2 (FastAPI + llama.cpp)
Pod Réplica N (FastAPI + llama.cpp)
Almacenamiento de Modelos
Montaje de volumen compartido
Disparo de escala
Escalador Horizontal (por cola y latencia)
Más réplicas del traductor